

Практическая работа 4

**Генеративно-сопоставительные сети (GAN): генерация изображений
CIFAR-10**

Выполнил(а): _____ (Фамилия И. О.)

Группа: _____

Преподаватель: _____

2026

1. Введение

Цель работы — изучить принципы работы генеративно-сопоставительных сетей на задаче генерации изображений. Реализуются и сравниваются две архитектуры: базовый GAN на полносвязных слоях (Vanilla GAN) и свёрточный DCGAN. В качестве данных взят набор CIFAR-10. В работе обучаются обе модели, отслеживается динамика потерь генератора и дискриминатора, оценивается качество генерации визуально и количественно (FID и Inception Score), а также показывается интерполяция в латентном пространстве.

2. Используемые инструменты

Работа выполнена на языке Python. Модели GAN построены и обучены на PyTorch, набор CIFAR-10 загружался через torchvision. Метрики FID и Inception Score считались с помощью torchmetrics и torch-fidelity. Для работы с массивами использовался NumPy, для построения изображений и графиков — Matplotlib. Обучение проводилось в среде Google Colab с подключённым графическим ускорителем.

3. Описание датасета

CIFAR-10 содержит 60000 цветных изображений размером 32 на 32 пикселя из десяти классов (самолёты, машины, птицы, кошки и другие). Для обучения используется обучающая часть из 50000 изображений. Картинки приводятся к диапазону от -1 до 1, чтобы соответствовать выходу генератора с функцией $\tanh$. Датасет скачивается автоматически через torchvision.




Рисунок 1 — Примеры реальных изображений CIFAR-10

4. Методология

Архитектуры. Vanilla GAN построен на полносвязных слоях: генератор превращает вектор шума в изображение, дискриминатор по вытянутому в вектор изображению решает, настоящее оно или нет. DCGAN построен на свёрточных слоях: генератор использует транспонированные свёртки с батч-нормализацией, дискриминатор — обычные свёртки. Свёрточная архитектура лучше подходит для изображений.

Обучение. Обе модели обучались сорок эпох. На каждом шаге сначала обновляется дискриминатор на реальных и сгенерированных изображениях, затем генератор так, чтобы обмануть дискриминатор. Использовалась функция потерь на основе бинарной кросс-энтропии, оптимизатор Adam со скоростью

обучения $2e-4$ и сглаживание меток реальных изображений для устойчивости. Качество оценивалось метриками FID и Inception Score.

5. Результаты

Динамика потерь. По графикам видно характерное для GAN поведение: потери генератора и дискриминатора колеблются и не стремятся к нулю, отражая их соревнование. У DCGAN обучение идёт устойчивее.




Рисунок 2 — Динамика потерь генератора и дискриминатора

Визуальная оценка. Vanilla GAN порождает шумные, плохо структурированные картинки, тогда как DCGAN выдаёт изображения с узнаваемыми очертаниями объектов, цветом и фактурой.




Рисунок 3 — Сгенерированные изображения Vanilla GAN




Рисунок 4 — Сгенерированные изображения DCGAN

Количественные метрики. DCGAN заметно превосходит Vanilla GAN по обеим метрикам, причём при меньшем числе параметров — свёртки используют их эффективнее. Метрики посчитаны на 5000 изображений (рекомендуется не менее 10000), поэтому абсолютные значения немного завышены, но соотношение моделей показательно.

Модель	FID (ниже лучше)	IS (выше лучше)	Параметры, млн	Сек/эпоху
Vanilla GAN	278,13	2,38	5,54	12,9
DCGAN	58,01	5,54	1,73	16,6

Интерполяция в латентном пространстве. При плавном переходе между двумя векторами шума изображения DCGAN меняются постепенно, без резких

скачков. Это говорит о том, что сеть выучила осмысленное представление, а не запомнила отдельные картинки.



Рисунок 5 — Интерполяция в латентном пространстве DCGAN

6. Ответы на контрольные вопросы

Как работает генеративно-состязательная сеть. GAN состоит из двух сетей, которые обучаются вместе и соревнуются. Генератор получает случайный шум и пытается превратить его в правдоподобное изображение, а дискриминатор учится отличать настоящие изображения от сгенерированных. Генератор стремится обмануть дискриминатор, а дискриминатор — не дать себя обмануть; в равновесии генератор выдаёт изображения, которые трудно отличить от настоящих.

Чем DCGAN лучше базового GAN. Базовый GAN на полносвязных слоях плохо улавливает пространственную структуру изображений, поэтому его картинки шумные и обучение нестабильно. DCGAN на свёрточных слоях с батч-нормализацией хорошо подходит для изображений: у него ниже FID, выше Inception Score, а картинки качественнее, причём достигается это при меньшем числе параметров.

Метрики FID и Inception Score. Inception Score оценивает сгенерированные изображения по уверенности классификатора и их разнообразию, чем выше, тем лучше. FID сравнивает распределения признаков настоящих и сгенерированных изображений, чем оно ниже, тем ближе сгенерированные картинки к настоящим. В работе DCGAN получил FID 58 против 278 у Vanilla GAN.

Динамика обучения и латентное пространство. Потери генератора и дискриминатора колеблются и не стремятся к нулю — это нормально для GAN и отражает их соревнование. Интерполяция в латентном пространстве показывает плавные переходы между изображениями, что говорит об осмысленном выученном представлении.

7. Выводы

Работа показала, что свёрточная архитектура DCGAN существенно превосходит базовый GAN на полносвязных слоях в задаче генерации изображений. DCGAN дал заметно более низкий FID и более высокий Inception Score при меньшем числе параметров, а его картинки визуально качественнее. Базовый GAN остаётся полезным как простая отправная точка, но для изображений свёрточный подход явно предпочтительнее. Качество можно поднять ещё, увеличив число эпох и применив продвинутые приёмы стабилизации обучения.